


## Partiel 8 octobre 2018 : Deep Learning

Jérôme Pasquet

### Exercice 1 [8 points]



Nous considérons le réseau ci-dessus constitué de 4 neurones appelés :  $n_1$ ,  $n_2$ ,  $n_3$ ,  $n_4$ . Nous notons  $w_i^{(j)}$  les différents poids associés au neurone  $j$ , avec  $i \in \{0..Nb \text{ d'entrées au neurone } j\}$ .

1. Nous notons  $o^{(j)}$  la sortie du neurone  $j$  avant d'appliquer sa fonction d'activation et  $s^{(j)}$  la sortie du neurone  $j$  après avoir appliqué la fonction d'activation, notée  $f$ . Donnez les équations de  $o^{(j)}$  et  $s^{(j)}$  pour chaque neurone. [1]

2. La fonction de perte est définie comme  $J = \frac{1}{2}(s^{(3)} - y_1)^2 + \frac{1}{2}(s^{(4)} - y_2)^2$ , avec  $y_1$  et  $y_2$  deux labels. Calculez la dérivée partielle  $\frac{\delta J}{\delta w_i^{(3)}}$ . [1]

3. En considérant la même fonction de perte, exprimez la dérivée partielle de  $\frac{\delta J}{\delta w_1^{(1)}}$  en fonction de l'erreur engendrée par les neurones parents  $n_3$  et  $n_4$ . [1]

4. Développez l'équation de  $\frac{\delta J}{\delta w_i^{(1)}}$ . [1]

5. Si nous considérons une fonction  $\tanh$ , développez l'équation  $\frac{\delta J}{\delta w_i^{(1)}}$ . [1]

6. Nous considérons désormais la fonction  $f(x) = PReLU(x) = \begin{cases} \alpha x & \text{si } x < 0 \\ x & \text{sinon} \end{cases}$ .

D'après vous, quel est l'intérêt de cette fonction comparée au  $ReLU$  ? [0.5 bonus]. Sachant que  $\alpha$  est un (hyper-)paramètre entraînable, calculez la mise à jour effectuée sur ce paramètre au niveau des neurones  $n_1$  et  $n_3$ . Nous notons  $\alpha^{(j)}$  l'hyper-paramètre du neurone  $j$ . [2]

7. Comment appelle-t-on  $x_3$ ? Quel est son utilité dans un réseau de neurones? [1]

### Exercice 2 [4 points]

1. Décrivez les différents facteurs qui rendent le Deep Learning prédominant dans les problèmes de classification modernes. [1]

2. Expliquez pourquoi la fonction  $ReLU$  est plus utilisée que la fonction  $\tanh$  dans les architectures modernes. [0.5]

3. Soit la fonction  $f(x) = x^2 + 0.8x - 0.5$ , trouvez le minimum global de cette fonction en expliquant votre méthode [0.5] et en détaillant les itérations effectuées. Vous partirez de la valeur  $x_0 = 4$ . [0.5]

4. Expliquez la notion de convolution 'étendue' dans les CNN. Utilisez un schéma. [0.5]
5. Appliquez la Conv 1 puis la Conv 2 à l'image en entrée. Donnez l'image finale. [1]

0	1	1	0	0	1	2	0
2	0	1	1	0	1	1	1
1	0	2	1	0	1	1	0
2	4	0	0	1	2	0	0
0	1	0	1	0	0	1	0
1	0	3	2	3	1	0	1
0	1	0	0	0	0	0	0
0	1	1	0	2	3	1	4

Conv 1  
Sans Padding  
Stride = 1

0	1	2
0	-2	0
-1	1	2

Conv 2  
Sans Padding  
Stride = 2

0	0	-1
1	0	-1
1	0	-1

### Exercice 3 [8 points]

Aide : La fonction `tf.split` fonctionne de manière similaire à la fonction `np.split`. Celles-ci divisent un tableau multidimensionnel en un ou plusieurs points selon un axe donné. Par exemple

- `np.split(np.array([2,3,4,5]), 2, axis=0)` retournera deux tableaux [2, 3] et [4, 5].
- `np.split(np.array([[2,3], [4,5], [6,7], [8,9]]), 2, axis=0)` retournera deux tableaux [[2,3], [4,5]] et [[6,7], [8,9]].

1. Des erreurs se sont glissées dans le code. Corrigez les directement sur le code.  
**Attention : aucune faute n'a été mise dans la fonction `getBatchTrain` et dans la variable `loss`.** [1]
2. Expliquez les labels en sortie de la fonction `getBatchTrain`. [1]
3. S'agit-il d'un problème de classification ? [0.25]
4. Quel est la taille des cartes de caractéristiques en sortie des couches `conv5` et `conv2`. [0.75]
5. Donnez la taille des noyaux de convolution des couches `conv5` et `conv2`. [0.5]
6. Que retourne les méthodes `conv5_a.shape` et `conv5.shape` ? [0.5]
7. Expliquez la fonction de perte utilisée. [1] D'après vous quel est son utilité ? [1]
8. Quel est l'objectif des premières couches de convolution? que se passe-t-il lorsqu'on analyse des convolutions à des niveaux plus 'profonds' ? [1]
9. Expliquez la différence entre une Variable TensorFlow, un Placeholder et une variable python. [0.5]
10. Comment fonctionne la méthode 'run' des objets de type 'Session' sous tensorflow? [0.5] Décrivez l'action de cette méthode sur trois types différents d'objets que vous présenterez. [0.5 bonus]

```

import tensorflow as tf
import numpy as np
import random

cifar10 = tf.keras.datasets.cifar10.load_data()

train_data = cifar10[0][0]
train_labels = cifar10[0][1]

BATCH_SIZE = 16

data = tf.placeholder(tf.bool, shape=(BATCH_SIZE, 3, 32, 32))
label = tf.placeholder(tf.float32, shape=(BATCH_SIZE/2))

def getBatchTrain(size):
    z = np.zeros((size, 32,32,3))

    label_tmp_1 = np.zeros((size/2))
    label_tmp_2 = np.zeros((size/2))
    for i in range(0, size/2):
        r=random.randint(0, train_data.shape[0]-1)
        tmp = train_data[r]
        f = random.random()
        z[i] = tmp
        label_tmp_1[i] = train_labels[r]
    for i in range(0, size/2):
        r=random.randint(0, train_data.shape[0]-1)
        tmp = train_data[r]
        f = random.random()
        z[i+size/2] = tmp
        label_tmp_2[i] = train_labels[r]
    l = label_tmp_1+label_tmp_2

    return z, l

conv1 = tf.layers.conv2d(
    inputs=data,
    filters=32,
    kernel_size=[3, 3],
    padding="same",
    activation=tf.nn.relu, bias_initializer = tf.constant_initializer(value=-0.1))

pool1 = tf.layers.max_pooling2d(conv1, 2, 2)

conv2 = tf.layers.conv2d(
    inputs=pool1,
    filters=64,
    kernel_size=[3, 3],

```

```

padding="same",
activation=tf.nn.relu, bias_initializer = tf.constant_initializer(value=-0.1))
pool2 = tf.layers.max_pooling2d(conv2, 2, 2)

conv3 = tf.layers.conv2d(
    inputs=pool2,
    filters=64,
    kernel_size=[3, 3],
    strides=1,
    padding="same",
    activation=tf.nn.relu, bias_initializer = tf.constant_initializer(value=-0.1))

conv4 = tf.layers.conv2d(
    inputs=conv3,
    filters=156,
    kernel_size=[3, 3],
    strides=1,
    padding="same",
    activation=tf.nn.relu, bias_initializer = tf.constant_initializer(value=-0.1))

pool4 = tf.layers.max_pooling2d(conv4, 2, 2)
conv5 = tf.layers.conv2d(
    inputs=pool4,
    filters=228,
    kernel_size=[3, 3],
    strides=1,
    padding="same",
    activation=tf.nn.relu, bias_initializer = tf.constant_initializer(value=-0.1))

conv5_a, conv5_b = tf.split(conv5, BATCH_SIZE/2, axis=0)

distance = tf.sqrt(tf.reduce_sum((conv5_a-conv5_b)**2))
loss = (1.0-train_labels) * tf.maximum(0.0, 1.0 -distance)+train_labels * distance

optimizer = tf.train.AdamOptimizer(0.00001)
train      = optimizer.minimize(loss)

sess = tf.Session()

init = tf.initialize_all_variables()
sess.run(sess)

for i in range(0, 10000):
    z, l = getBatchTrain(size=BATCH_SIZE)
    _, loss_r = sess.run([train, loss], feed_dict={data:z, label:l})
    print i, loss_r

```